강원대학교
AI 소프트웨어학과

# 머신러닝2

## - 지도학습 –

### 기계학습의 회귀분석

KNU
강원대학교

## 통계적 방법과 기계학습 방법의 차이

### 기계학습의 방법(지도학습)

- 다중 회귀분석(Regression)
- 로지스틱 회귀분석(Logistic Regression)
- 신경망(Atificial Neural Network)
- 서포트 백터 머신(Support Vector Machine)
- 의사결정나무(Decision Tree)
- 앙상블(Ensemble)
- K-근접 이웃기법(k-Nearest Neighbor)

## 로지스틱 회귀(Logistic Regression)

### 연속형 종속변수 경우?

- 독립변수를 바탕으로 종속변수를 예측함
- 강아지, 고양이와 같은 연속적이지 않은 범주형 변수를 어떻게 예측할까?

| 지점번호 | 홍보비용 | 직원수 | 지점성과 | 고객수 | 대출정도 | 유동인구 | 예금금액 |
|---|---|---|---|---|---|---|---|
| 1 | 40 | 15 | | | | | 2,000 |
| 2 | 50 | 20 | | | | | 3,500 |
| 3 | 30 | 14 | | | | | 4,000 |
| 4 | 60 | 22 | | | | | 3,500 |
| 5 | 70 | 30 | | | | | 4,900 |
| 6 | 60 | 24 | | | | | 3,100 |
| 7 | 30 | 16 | | | | | 4,200 |
| 8 | 60 | 20 | | | | | 2,300 |
| 9 | 20 | 14 | | | | | 6,000 |
| 10 | 80 | 32 | | | | | 5,000 |

## 로지스틱 회귀(Logistic Regression)

**연속형 종속변수가 아닌 범주형 종속변수일 경우?**

- 질병 진단(0 = 양성, 1 = 악성)
- 강아지, 고양이 판단

| 지점번호 | 홍보비용 | 직원수 | 지점성과 | 고객수 | 대출정도 | 유동인구 | 예금유지 |
|---|---|---|---|---|---|---|---|
| 1 | 40 | 15 | | | | | 0 |
| 2 | 50 | 20 | | | | | 1 |
| 3 | 30 | 14 | | | | | 1 |
| 4 | 60 | 22 | | | | | 1 |
| 5 | 70 | 30 | | | | | 1 |
| 6 | 60 | 24 | | | | | 1 |
| 7 | 30 | 16 | | | | | 0 |
| 8 | 60 | 20 | | | | | 1 |
| 9 | 20 | 14 | | | | | 0 |
| 10 | 80 | 32 | | | | | 1 |

## 로지스틱 회귀(Logistic Regression)

**연속형 종속변수가 아닌 범주형 종속변수일 경우?**

- **시그모이드 함수(Sigmoid Function) :** $0 < \sigma(y) < 1$ **사이의 값으로 구성되어 확률처럼 해석하기 좋음**
- **이진분류의 문제를 해결하기 위해 많이 사용**
- **활성화 함수(Activation Function)으로도 많이 사용됨(Forward → Loss → Backward → Optimizer)**

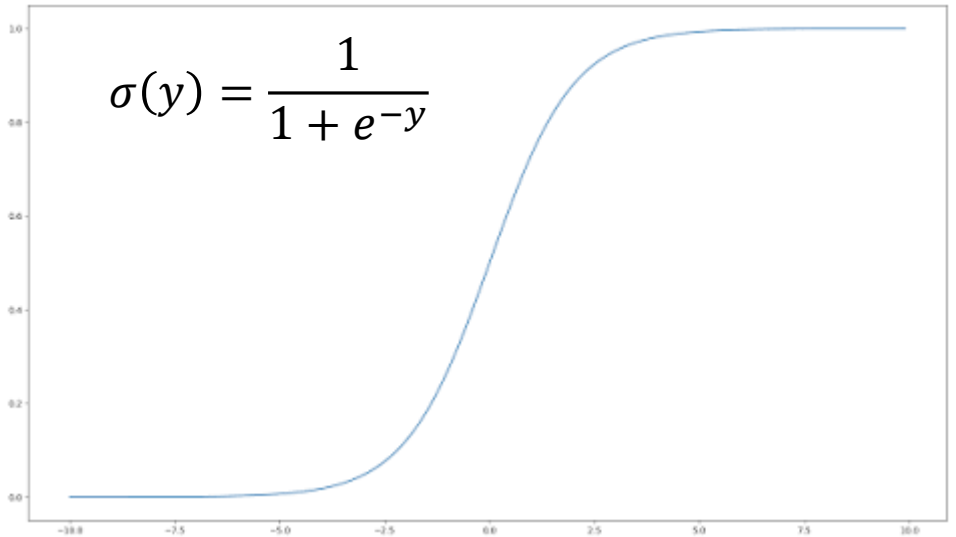

## 로지스틱 회귀(Logistic Regression)

**연속형 종속변수가 아닌 범주형 종속변수일 경우?**

- **로지스틱 회귀분석(Logistic Regression) : 로지스틱 회귀 모델은 시그모이드 함수라고도 알려진 로지스틱 함수를 사용하여 예측값을 확률에 매핑해 0과 1로 도출함**
- **질병 진단(0 = 양성, 1 = 악성)**
- **강아지, 고양이 판단**

$$y = \beta_0 + \beta_1 x_1 + \beta_n x_n + \cdots + \beta_n x_n$$ ⟹ **연속적인 수치정보를 제공함**

⇓

$$\sigma(y) = \frac{1}{1 + e^{-y}}$$ ⟹ **이분류 문제로 데이터 값을 변경함**

## 로지스틱 회귀(Logistic Regression)

**연속형 종속변수가 아닌 범주형 종속변수일 경우?**

- **로지스틱 회귀분석(Logistic Regression) : 로지스틱 회귀 모델은 시그모이드 함수라고도 알려진 로지스틱 함수를 사용하여 예측값을 확률에 매핑해 0과 1로 도출함**
- **질병 진단(0 = 양성, 1 = 악성)**
- **강아지, 고양이 판단**

$$y = \beta_0 + \beta_1 x_1 + \beta_n x_n + \cdots + \beta_n x_n$$

$$\sigma(y) = \frac{1}{1 + e^{-y}}$$

$$\beta_0 = -1,\ \beta_1 = 0.8,\ x_1 = 2, x_2 = 3$$

$$y = -1 + (0.8 * 2) - (0.5 * 3) = -0.9$$

$$\sigma(y) = \frac{1}{1 + e^{-(-0.9)}} = 0.289$$

**고양이 판단**

# 로지스틱 회귀(Logistic Regression)

## 로지스틱 회귀

| 크기 | 진단 |
|---|---|
| 100 | 0 |
| 101 | 0 |
| 102 | 0 |
| 103 | 0 |
| 104 | 0 |
| 105 | 0 |
| 106 | 0 |
| 107 | 0 |
| 108 | 0 |
| 109 | 0 |
| 110 | 1 |
| 111 | 1 |
| 112 | 1 |
| 113 | 1 |
| 114 | 1 |

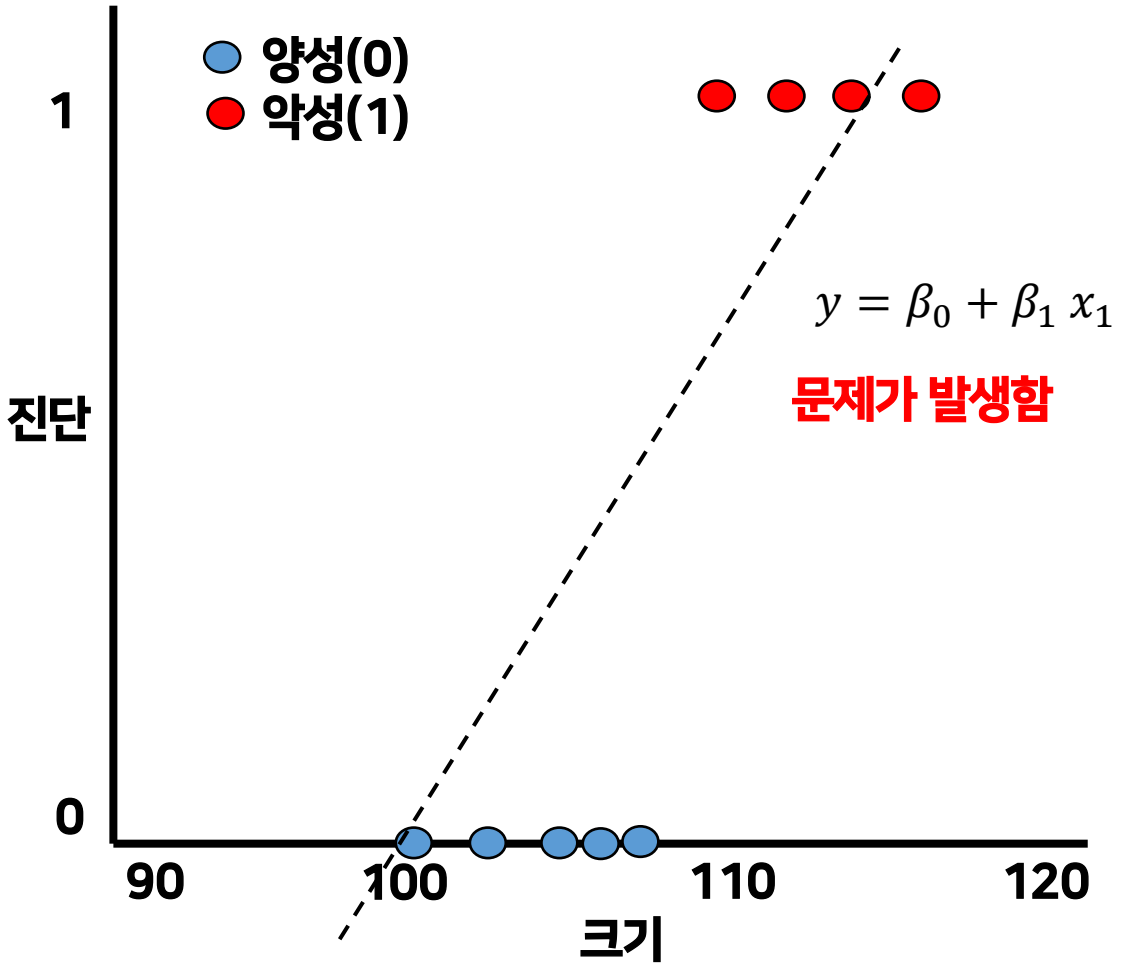

## 로지스틱 회귀(Logistic Regression)

### 로지스틱 회귀

| 크기 | 예측확률 | 진단 |
|---|---|---|
| 100 | 0.005 | 0 |
| 101 | 0.007 | 0 |
| 102 | 0.009 | 0 |
| 103 | 0.01 | 0 |
| 104 | 0.02 | 0 |
| 105 | 0.05 | 0 |
| 106 | 0.1 | 0 |
| 107 | 0.4 | 0 |
| 108 | 0.5 | 0 |
| 109 | 0.6 | 0 |
| 110 | 0.65 | 1 |
| 111 | 0.7 | 1 |
| 112 | 0.75 | 1 |
| 113 | 0.8 | 1 |
| 114 | 0.9 | 1 |

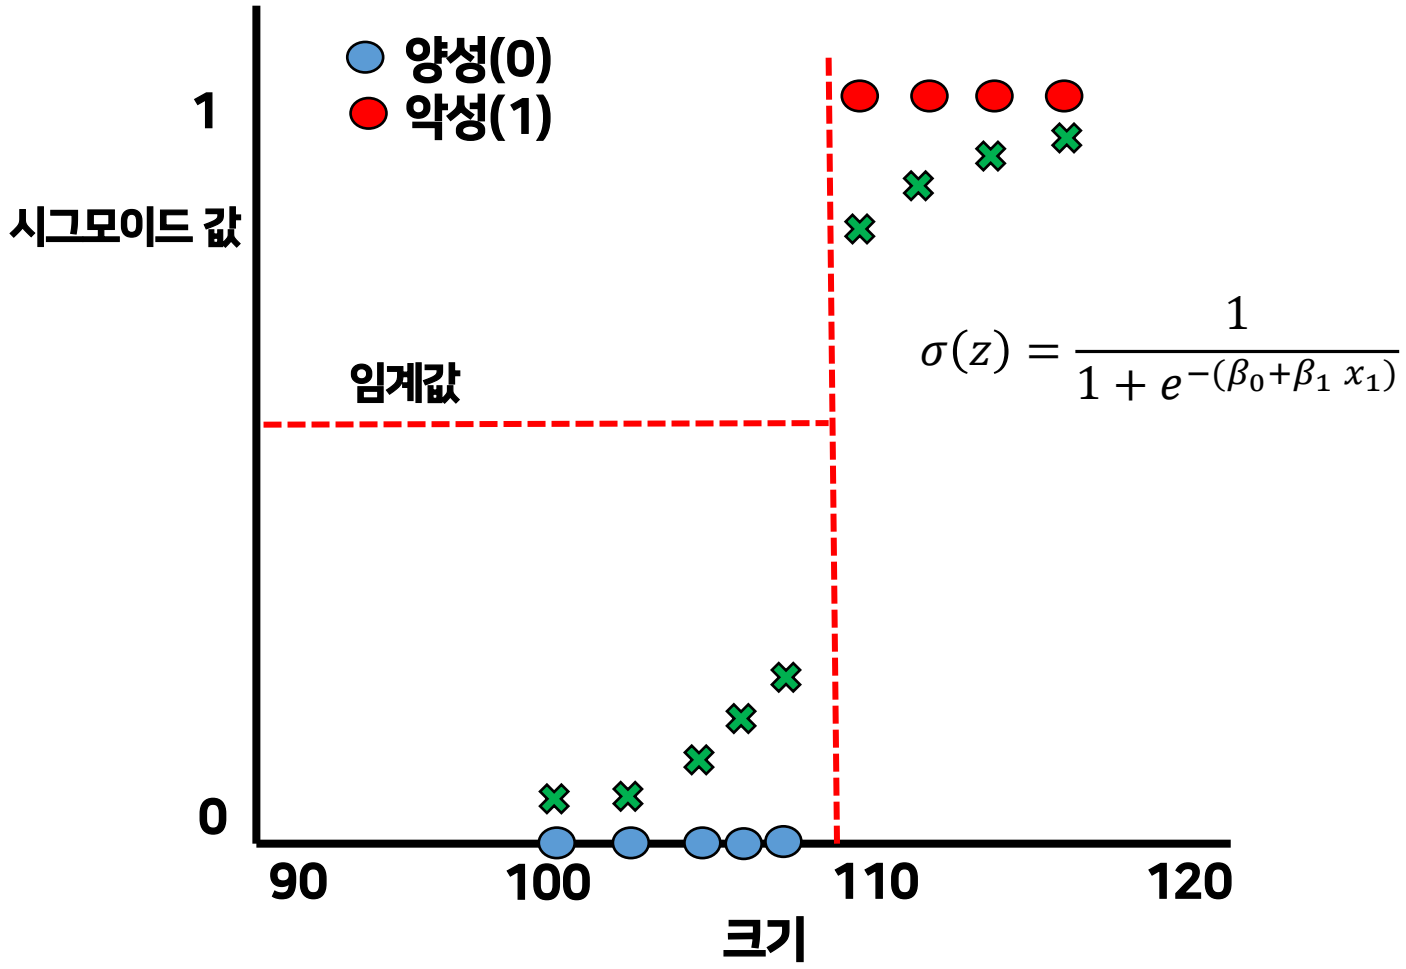

# 로지스틱 회귀(Logistic Regression)

## 로지스틱 회귀

| 크기 | 수치 | 진단 |
|---|---|---|
| 100 | 5 | 0 |
| 101 | 6 | 0 |
| 102 | 7 | 0 |
| 103 | 4 | 0 |
| 104 | 5 | 0 |
| 105 | 7 | 0 |
| 106 | 4 | 0 |
| 107 | 6 | 0 |
| 108 | 8 | 0 |
| 109 | 5 | 0 |
| 110 | 8 | 1 |
| 111 | 5 | 1 |
| 112 | 7 | 1 |
| 113 | 9 | 1 |
| 114 | 8 | 1 |

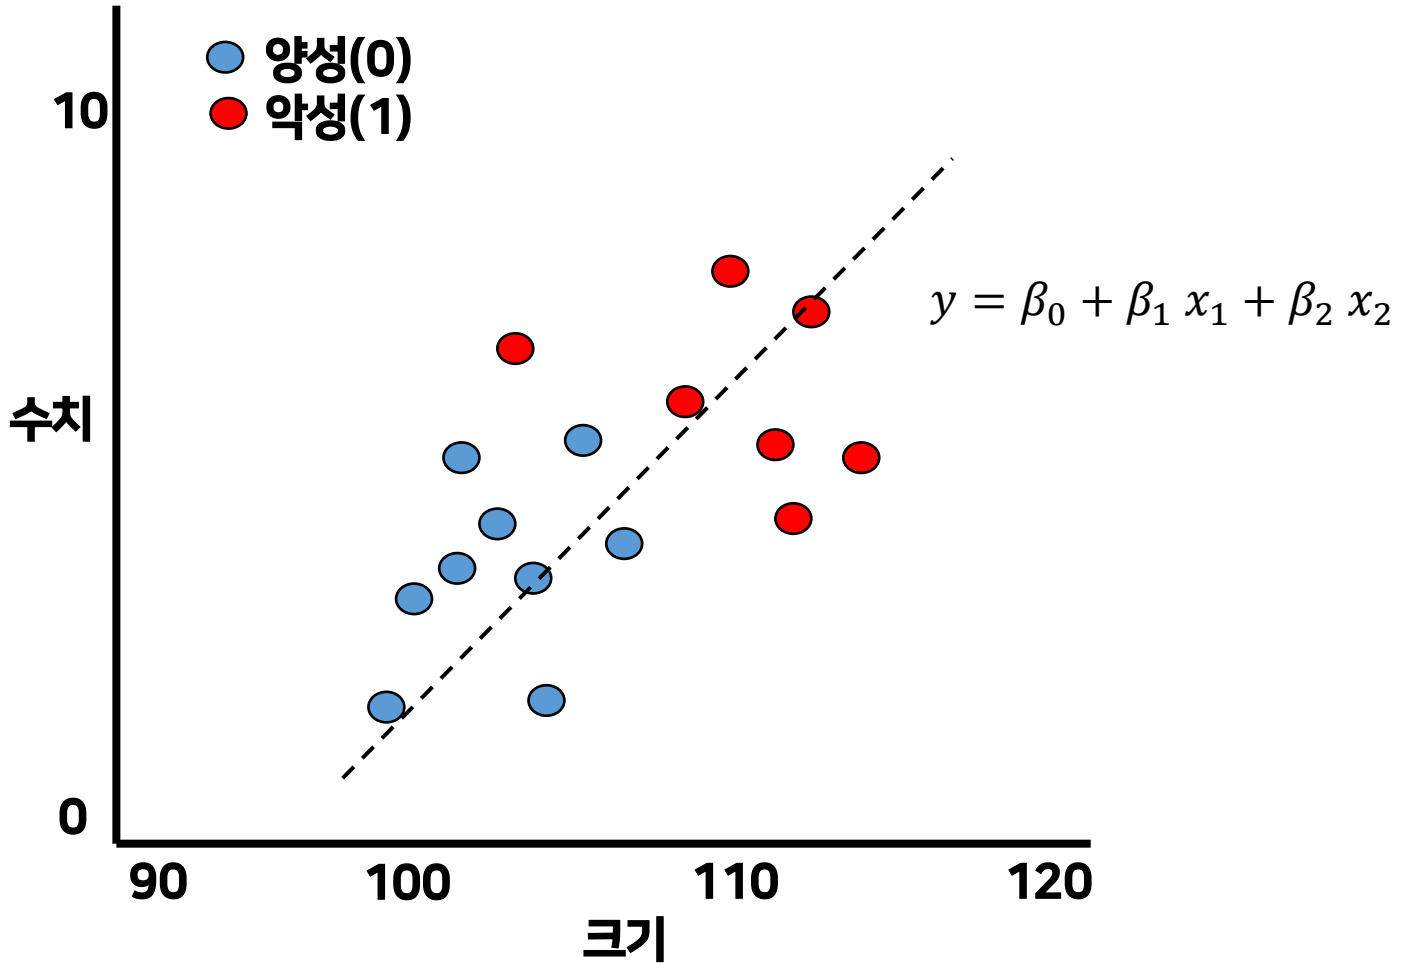

# 로지스틱 회귀(Logistic Regression)

## 로지스틱 회귀

| 크기 | 수치 | 진단 | 예측확률 |
|---|---|---|---|
| 100 | 5 | 0 | 0.005 |
| 101 | 6 | 0 | 0.007 |
| 102 | 7 | 0 | 0.009 |
| 103 | 4 | 0 | 0.01 |
| 104 | 5 | 0 | 0.02 |
| 105 | 7 | 0 | 0.05 |
| 106 | 4 | 0 | 0.1 |
| 107 | 6 | 0 | 0.4 |
| 108 | 8 | 0 | 0.5 |
| 109 | 5 | 0 | 0.6 |
| 110 | 8 | 1 | 0.65 |
| 111 | 5 | 1 | 0.7 |
| 112 | 7 | 1 | 0.75 |
| 113 | 9 | 1 | 0.8 |
| 114 | 8 | 1 | 0.9 |

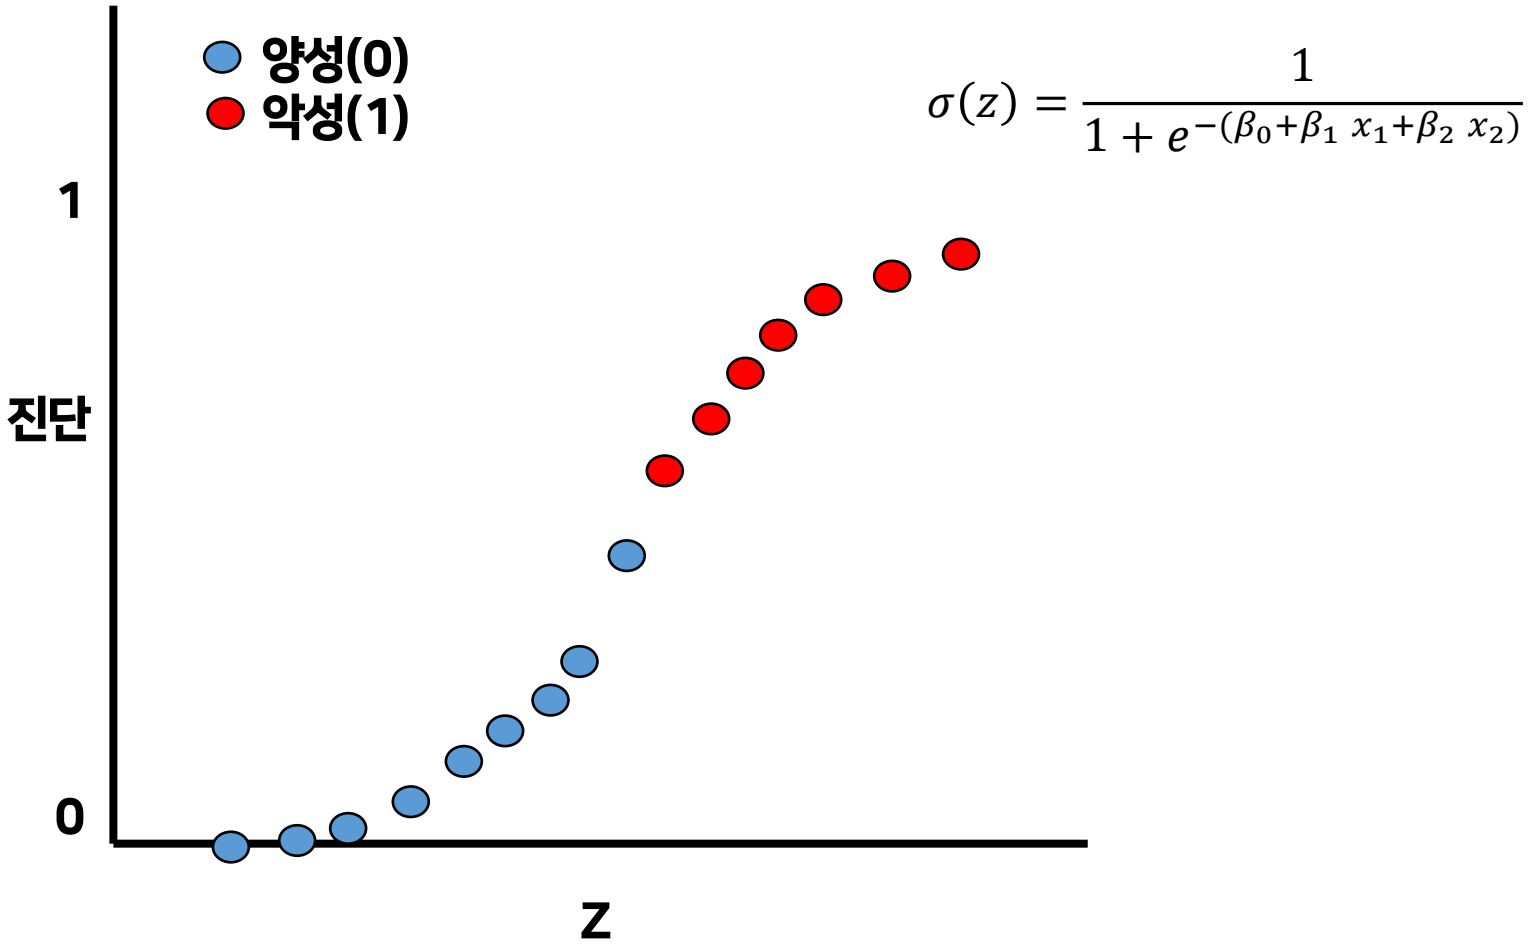


$$\sigma(z) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \beta_2 x_2)}}$$

## 로지스틱 회귀(Logistic Regression)

### 로지스틱 회귀분석

```
library(GGally)
library(skimr)
library(tidyverse)
library(tidymodels)
library(caret)

df <- read.csv("UniversalBank.csv", header = TRUE, na = ".“)
skim(df)

df$Personal.Loan <- ifelse(df$Personal.Loan == 1, "yes", "no")
df$Personal.Loan <- as.factor(df$Personal.Loan)

trainIndex <- createDataPartition(df$Personal.Loan, p = 0.8, list = FALSE)
train_data <- df[trainIndex,]
test_data <- df[-trainIndex,]
```

## 로지스틱 회귀(Logistic Regression)

### 로지스틱 회귀분석

```
result=glm(train_data$Personal.Loan ~., data= train_data, family = “binomial”)

tidy_result <- tidy(result)
tidy_result <- mutate_if(tidy_result, is.numeric, round, 3)

print(tidy_result)
```

## 로지스틱 회귀(Logistic Regression)

### 로지스틱 회귀분석

```
library(car)
library(broom)
library(dplyr)

# 다중공선성(변수의 중복성) : 8이상 GVIF^(1/(2*DF))
vif(result)

# 다중공선성 위배 변수제거 후 다시 분석
result=glm(train_data$Personal.Loan ~., data= train_data, family = “binomial”)

# Cook's distance 계산 (glm에도 사용 가능)
influencePlot(result, id.method="identify")
```

## 로지스틱 회귀(Logistic Regression)

### 로지스틱 회귀분석

```
# 기준 설정
# 상위 몇 %를 영향점으로 봄
cooks_d <- cooks.distance(result)
cooks_dn <- nrow(train_data)

#Cooks'D값을 cutoff보다 큰 관측치만 추출
cutoff <- 4 / ncutoff
influential_idx <- which(cooks_d > cutoff)

influential_idx
```

## 로지스틱 회귀(Logistic Regression)

### 로지스틱 회귀분석

```
# Test 데이터셋 결과
test_predictions <- predict(result, newdata = test_data, type = "response")
predicted_class <- ifelse(test_predictions > 0.5, "yes", "no")
predicted_class <- as.factor(predicted_class)
print(predicted_class)

# 모델 저장
saveRDS(result, file = "logistic_model.rds")

# 모델 로드
Load <-readRDS("logistic_model.rds")

tidy_result <- tidy(Load)
tidy_result
tidy_result <- mutate_if(tidy_result, is.numeric, round, 3)
```

## 로지스틱 회귀(Logistic Regression)

### 모델검정

- 수치형 : RMSE, R-Squared($R^2$)
- 범주형 : Accuracy, ROC Curve
  - Precision(정밀도) : 모델에 의해 수행된 모든 긍정적인 예측 중 실제 긍정적인 예측의 비율
    - 장난감 상자에 10번 장난감을 꺼낼 경우, 10번 중에서 장난감 7개와 기타 물건 3개(책, 양말, 연필 등)를 선택함 → 내가 "장난감이다" 라고 집어 든 것들 중에서 진짜 장난감 비율
  - Recall(재현율) : 모든 실제 양성 사례 중 참양성 예측의 비율(남아있는 장난감)
    - 상자에 10개의 장난감이 있다고 상상할 때(더 있을수도 있음), 10개의 장난감 중에서 7개를 찾음 → 리콜은 당신이 발견한 상자 속 장난감의 총 개수에 관한 것 → 상자에 장난감이 총 10개 있었고 그중 7개를 찾았다면 7/10
  - Accuarcy(정확도) : 전체 예측 정답 중 얼마나 올바르게 예측했는가에 대한 비율
  - F1 Score : Precision와 Recall의 조화 평균 → Label의 성능이 불균형일 경우 정확하게 평가할 수 있음

## 로지스틱 회귀(Logistic Regression)

### 모델검정

- **Precision(정밀도) :** $\frac{TP}{TP+FP}$
- **Recall(재현율) :** $\frac{TP}{TP+FN}$
- **Accuracy(정확도) :** $\frac{TP+TN}{TP+FN+FP+TN}$
- **F1-Score :** $2 \times \frac{Precision \times Recall}{Precision+Recall}$

| | | 실제 정답 | |
|---|---|---|---|
| | | True(환자) | False(정상) |
| 분류결과 | True(환자) | TP(20) | FP(40) |
| | False(정상) | FN(30) | TN(10) |

Precision

Recall

## 로지스틱 회귀(Logistic Regression)

### 모델검정

- 높은 Precision, 낮은 Recall → Precision : 내가 잡은 것들 중에 장난감의 비율 → 내선택에서 참의 비율

| | | 실제 정답 | |
|---|---|---|---|
| | | True(장난감) | False(물건) |
| 분류결과 | True(장난감) | TP(5) | FP(0) |
| | False(물건) | FN(4) | TN(2) |

- 높은 Recall, 낮은 Precision → Recall : 상자 안 모든 장난감 중 내가 찾아낸 장난감의 비율 → 참을 얼마나 놓치지 않았나?

| | | 실제 정답 | |
|---|---|---|---|
| | | True(장난감) | False(물건) |
| 분류결과 | True(장난감) | TP(4) | FP(2) |
| | False(물건) | FN(2) | TN(2) |

- 높은 Precision 및 높은 Recall:9개 물건을 집었고 9개 모두 장난감이었고 상자에 장난감이 1개만 남아 있었다면 높은 Precision(장난감만 집은 것)과 높은 Recall(거의 모든 장난감을 찾았음)을 모두 갖게 됨

## 로지스틱 회귀(Logistic Regression)

### 모델검정

- ROC(Receiver Operating Characteristic)
- TPR(True Positive Rate) : 실제 클래스 True중에 잘 맞춘 것 → 4/6
- FPR(False Positive Rate) : 실제 클래스 False중에 못 맞춘 것 → 2/4

| | | 실제 정답 | |
|---|---|---|---|
| | | True(장난감) | False(물건) |
| 분류결과 | True(장난감) | TP(4) | FP(2) |
| | False(물건) | FN(2) | TN(2) |

0.5 : 무작위 수준 → 나쁨

0.6~0.7 : 낮음

0.7~0.8 : 보통

0.8~0.9 : 좋음

0.9 이상 : 매우좋음

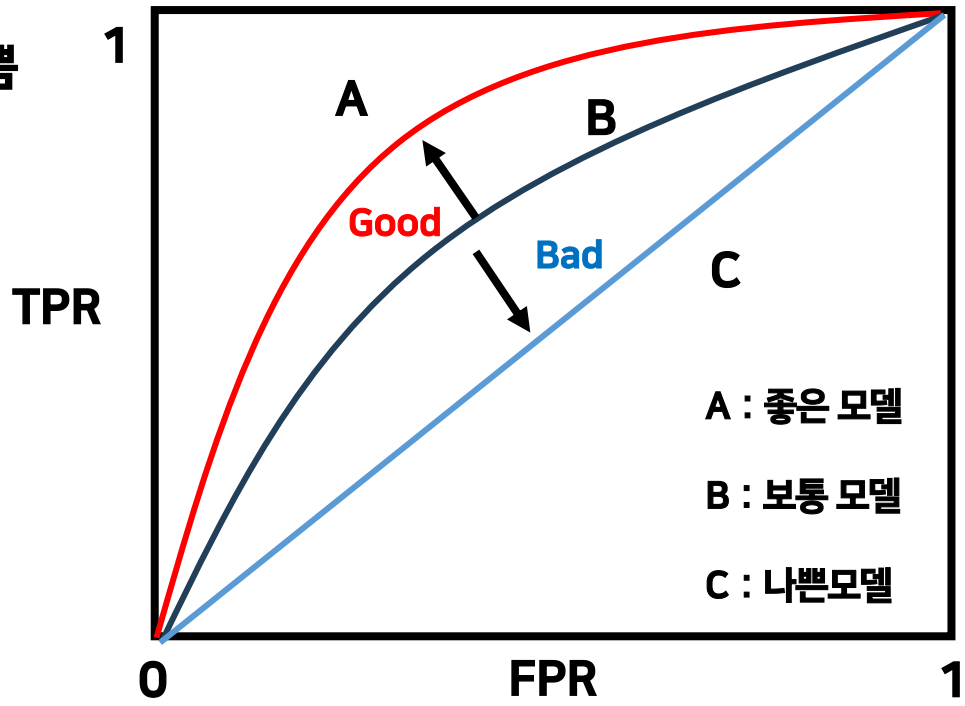


진짜를 얼마나 놓치지 않고 찾았는가?

$$TPR = \frac{TP}{TP + FN}$$

가짜를 얼마나 착각했는가?

$$FPR = \frac{FP}{FP + TN}$$

# 로지스틱 회귀(Logistic Regression)

## 임계값을 내리는 경우

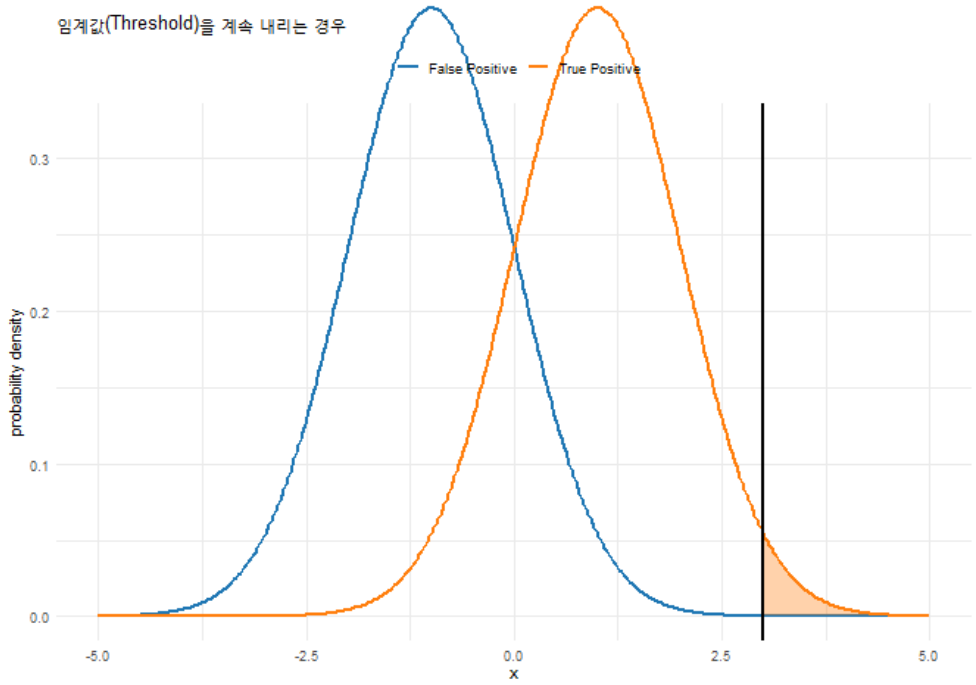


## 임계값을 올리는 경우

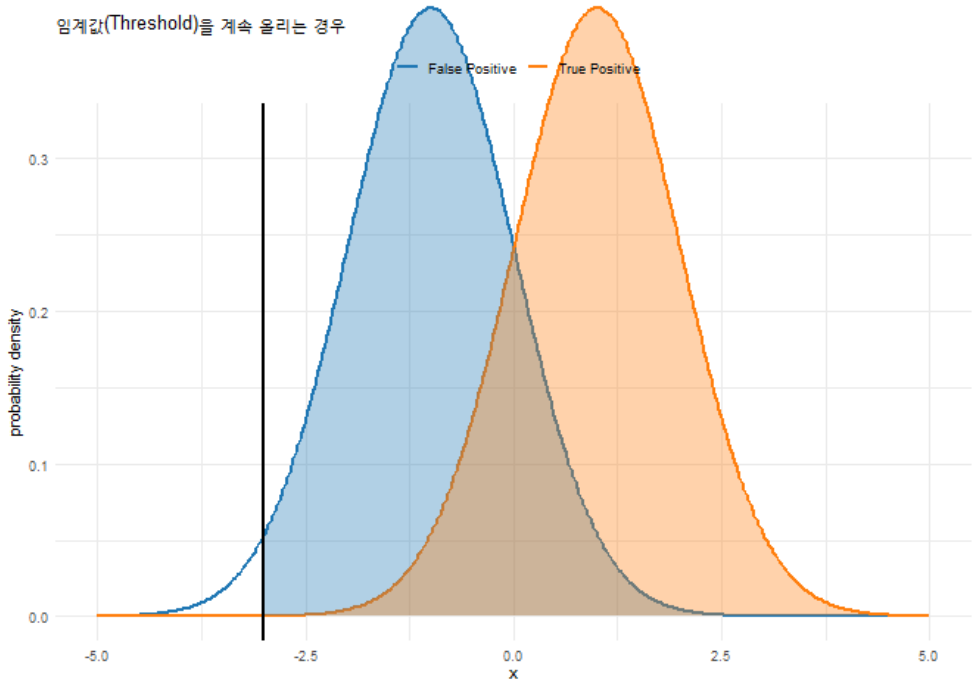


# 로지스틱 회귀(Logistic Regression)

## ROC커브가 그려지는 과정

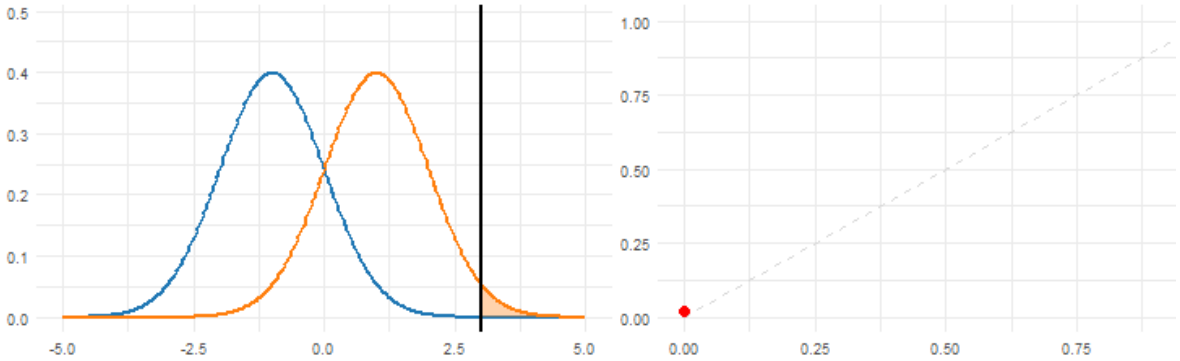


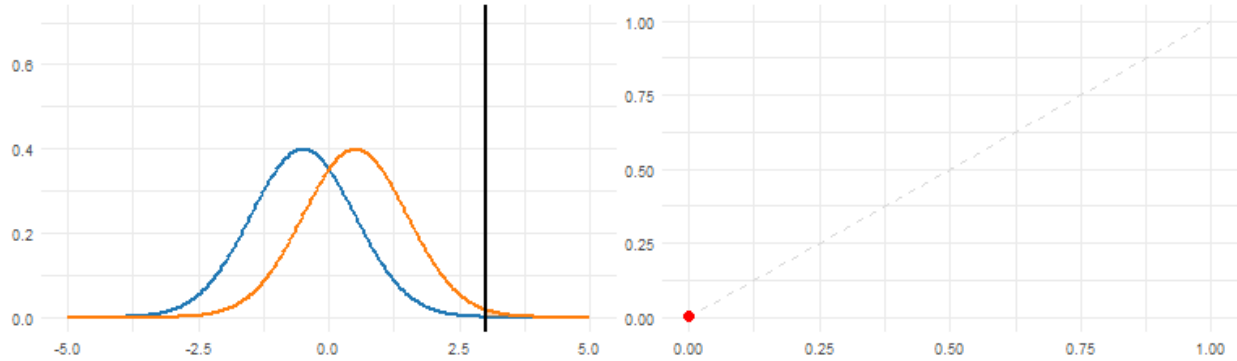


## 두 집단의 거리가 멀어질수록 ROC커브가 왼쪽 위로 올라감 → 좋은 결과

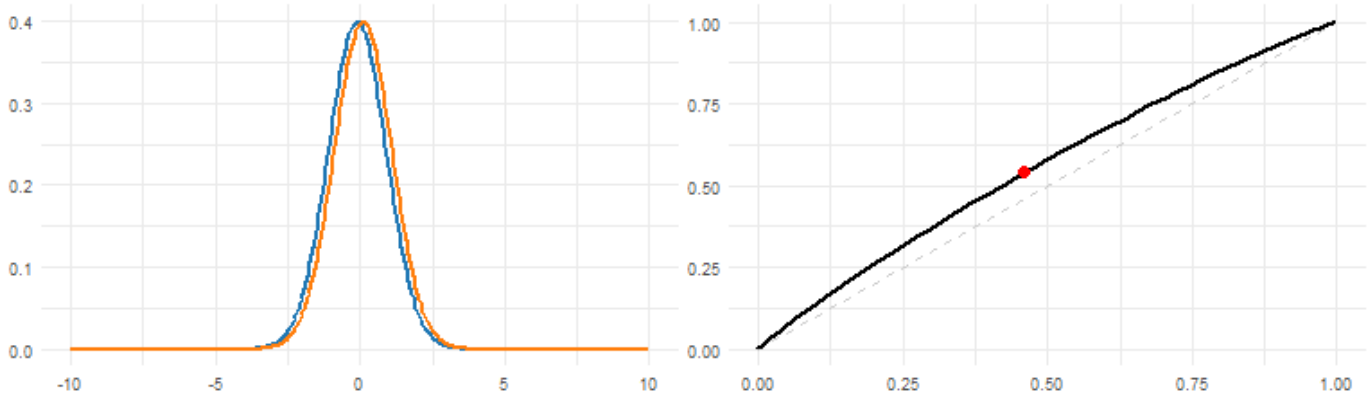

## 로지스틱 회귀(Logistic Regression)

### 모델검정

- ROC(Receiver Operating Characteristic)
- TPR(True Positive Rate) : 실제 클래스 True중에 잘 맞춘 것 → 4/6
- FPR(False Positive Rate) : 실제 클래스 False중에 못 맞춘 것 → 2/4

| | | 실제 정답 | |
|---|---|---|---|
| | | True(장난감) | False(물건) |
| 분류결과 | True(장난감) | TP(4) | FP(2) |
| | False(물건) | FN(2) | TN(2) |

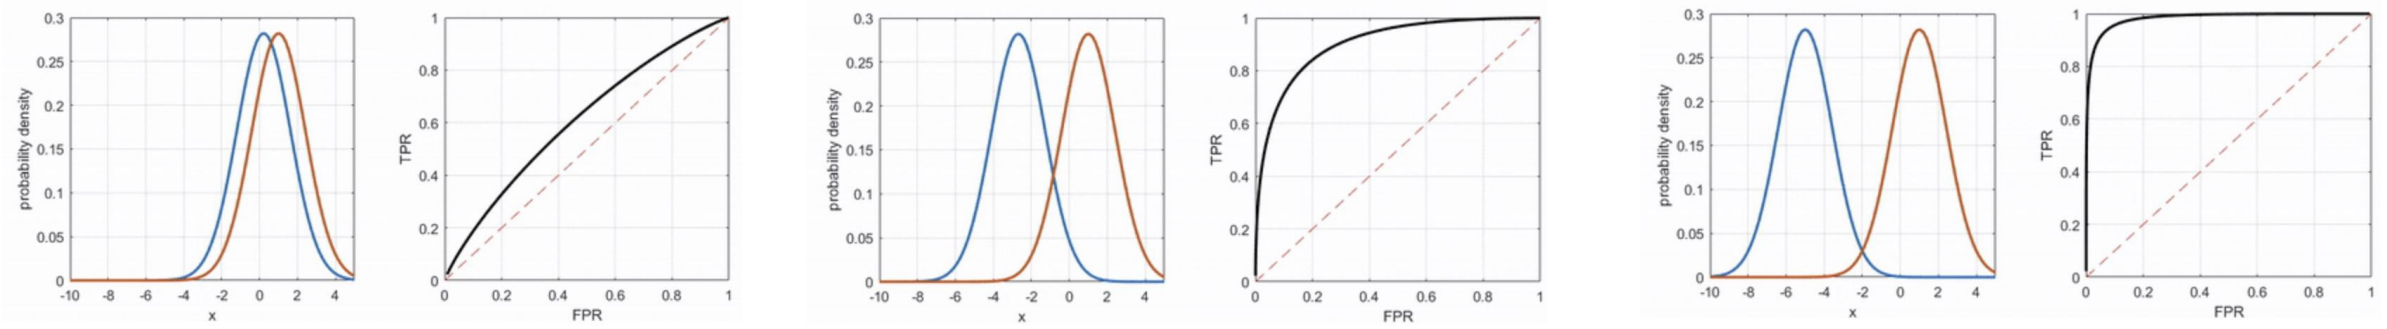

## 로지스틱 회귀(Logistic Regression)

### 로지스틱 회귀분석(ROC Curve)

```
library(pROC)
library(caret)
library(e1071)

# 모델의 Confusion matrix
confusion_matrix <- confusionMatrix(predicted_class, test_data$Personal.Loan)
confusion_matrix

#Mcnemar's Test P-Value(혼동행렬에서 오류가 비대칭인지 파악 : 0.05보다 크면 데이터가 대칭적)
#Kappa(데이터가 한쪽이 너무 많을 때, 한쪽의 값을 도출해도 정확도가 높기 때문에 우연으로 맞췄는지 실제로 맞췄는지를 평가함)
#Kappa값이 1에 가까울 수록 좋은 모델, -값을 가지면 무작위로 예측하는 것 보다 정확도가 낮다는 의미(과적합 판단)

# ROC curve and AUC
roc_curve <- roc(test_data$Personal.Loan, test_predictions)
plot(roc_curve)
auc(roc_curve)
```

## 로지스틱 회귀(Logistic Regression)

### 로지스틱 회귀분석(ROC Curve)

```
# 새로운 데이터를 활용한 모델 적용
df_test <- read.csv("UniversalBank_test.csv", header=TRUE)
```